

RAG는 죽었다는 오해, 그리고 진화

단순 검색(Naive RAG)의 종말과
컨텍스트 엔지니어링(Context
Engineering)의 비즈니스적 가치



오해: 코딩 에이전트의 등장과 RAG is Dead 논란

```
>_ search.files('structured/data')
>_ finding path: /src/main/java/com/example/service/
>_ ... 27 files found.
>_ match: StructuredDataProvider.java
>_ context: implements StructuredDataProvider...
```

구조화된 코드(Structured Data)를 찾을 때는
에이전트가 직접 터미널 도구로 파일 구조를 탐색하는
것이 압도적으로 빠르고 정확합니다.

진실: 하지만, 우리가 다루는 데이터는 코드가 아닙니다

비정형 데이터 (Unstructured Data)



계약서에서 '손해 배상'을 찾으려면 정확한 문자열이 아닌
'배상 책임, 면책 사유' 등 의미(Semantic)를 찾아야 합니다.
비정형 비즈니스 환경에서 RAG는 여전히
대체 불가능한 인프라입니다.


RAG의 본질: AI에게 허락된 '오픈북 시험'

파운데이션 모델 (LLM 단독)




학습이 끝난 시점에서 지식이 멈춥니다.
사내 최신 규정이나 고객 데이터를 알 수 없어
환각(Hallucination)이 발생합니다.

RAG (Retrieval-Augmented Generation)



질문을 받으면 관련된 외부 문서를 먼저
검색(Retrieval)한 뒤, 이를 참고하여 답변을
생성(Generation)합니다.
근거 있는 답변이 가능해집니다.

실패하는 RAG의 90%는 '검색(Retrieval)'에서 무너집니다




Your Chunk is Junk.
(청크가 쓰레기면 결과도 쓰레기다)

대부분의 문제는 LLM의 생성 능력이 아니라,
엉뚱한 정보 조각(Chunk)을 검색해 오는 데서 발생합니다.
이를 해결하기 위해 검색 파이프라인의 부품들을 정교하게 조립해야 합니다.

인베딩(Embedding)과 벡터: 텍스트를 '의미의 좌표'로 변환하다

The Vector Space



의미가 비슷할수록 좌표상 거리가 가깝습니다.

The Supermarket Metaphor




마트에서 만두와 파전이 같은 냉동코너(유사한 좌표)에 있는 것과 같습니다.

단어가 아닌 '의미'로 검색(Semantic Search).
'과일 알레르기'를 검색해도 '식품 안전 규정'을 찾아냅니다. (작은 모델은 384차원, 큰 모델은 3072차원의 좌표계를 가집니다).

청킹(Chunking) 전략: 문서를 어떻게 자를 것인가?

기준	작동 방식 및 장점	단점 및 리스크
길이 기반 (Length-based)	500자 등 기계적 분할. 구현이 매우 쉬움.	문장 중간이 잘려 정보와 맥락이 영구적으로 손실됨.
의미 기반 (Semantic-based)	문단이나 의미 단위로 분할. 맥락 보존율이 높음.	구현 난이도가 높고 처리 속도가 현저히 느림.




숨은 관문: 파서(Parser).

문서에 표(Table)나 이미지가 섞여 있다면 청킹 난이도는 급상승합니다.
전문 파싱 모델로 텍스트를 깔끔하게 추출하는 것이 첫 단추입니다.

벡터 데이터베이스(Vector DB): '정확한 주소' 대신 '비슷한 이웃' 찾기

일반 데이터베이스 (RDBMS)




```
SELECT * WHERE Name = '홍길동'
```

“ 3번 통로 4번 선반 1035번 상품 가져와. ”

(정확한 조건 검색)

벡터 데이터베이스 (Vector DB)



```
Find nearest neighbors to Vector  
[0.12, -0.45, 0.78]
```

“ 이 만두(숫자 배열)랑 가장 비슷한 상품들 다 찾아줘. ”

(유사도 검색 특화)

검색 전략 매트릭스: 의미와 키워드의 결합 (Hybrid Search)



덴스 임베딩 (Dense / Semantic)

원리

텍스트의 '의미'를 뽁뽁한 벡터로 압축.
(‘이 문장이 무슨 뜻이야?’)

강점

유의어, 맥락 파악 우수.

한계

‘CVD 챔버’, ‘BWG 전환청구권’ 같은
희귀 전문 용어 매칭에 취약.



스파스 임베딩 (Sparse / Keyword)

원리

특정 단어의 등장 빈도 기반.
대부분의 차원이 0 (희소함).
(‘이 단어가 어디 있어?’)

강점

제조/금융 등 도메인 특수 용어의
정확한 타겟팅.

한계

단어가 다르면 의미가 같아도 찾지 못함.



하이브리드 서치 (Hybrid Search)


원리

두 가지 검색의 **가중치를 조절하여**
결합.

전략적 적용

범용 문서 = Dense 비중 UP.
전문 문서 = Sparse 비중 UP.
가장 강력한 실무 표준.

리랭커(Reranker) 퍼널: 넓게 찾고 정밀하게 걸러내기



1차 검색 (Broad Net)

'주선자의 1차 필터링'.
벡터/하이브리드 검색으로 조건에 맞는 후보 10개 추출 (빠르지만 노이즈 포함).

리랭커 (The Filter)


'실제 만남 및 심층 평가'.
질문과 청크를 나란히 놓고 LLM 기반으로 맥락을 정밀하게 재평가 및 점수 부여.

최종 도출 (Top 3)

가장 적합한 최종 청크 도출.

Trade-off: 정확도(Accuracy)는 대폭
상승하지만 연산 속도(Speed)는 저하됨.
B2C 대규모 서비스 적용 시 병목 현상 주의.

실무의 한계: 청킹 과정에서의 '맥락 소실 (Context Loss)'



어느 회사의? 언제적 매출?

이 청크만으로는 검색 엔진이 '삼성전자 2분기 매출'이라는 질문에 대답할 수 없습니다.


고급 기법: 잃어버린 맥락(Context)을 복원하는 두 가지 방법

컨텍스트 리트리벌 (Contextual Retrieval)



- 자른 후(Chunking) -> LLM을 호출하여 각 청크마다 원본의 맥락을 요약해 덧붙임.
- 검색 실패율 최대 67% 감소 (Anthropic).
- 비용 절감을 위해 쓸모없는 청크를 걸러내는 이진 판별기 도입 권장.

레이트 청킹 (Late Chunking)



- 문서 전체를 한 번에 임베딩하여 전체 맥락을 파악한 후 -> 나중에 자름(Chunking).
- 영화를 처음부터 끝까지 다 본 뒤에 장면별로 요약하는 원리.
- 문맥 단절을 원천적으로 차단.

‘RAG는 죽었다?’ 데이터의 성질에 따른 오해



구조화된 데이터 (Structured Data)

함수명, 변수명, 파일 경로 등.
(예: 코드 베이스)

에이전트 직접 탐색(Agentic Search) 유리. RAG 불필요.



비정형 데이터 (Unstructured Data)

고객 문의, 사내 위키, 법률 계약서,
마케팅 리포트.
지식 베이스가 테라바이트 단위일 때.


의미 기반 탐색 필수
(Semantic Search).
Advanced RAG 필수.

(Long-context 창에 모두 넣는 것 대비 비용 8~12배 저렴)


RAG는 죽은 것이 아니라, 요구 수준이 올라갔을 뿐입니다.

RAG의 진화: 단순 벡터 검색에서 '컨텍스트 엔지니어링'으로


과거: 단순하고 취약한 파이프라인



현재: 정교한 컨텍스트 엔지니어링 (Context Engineering)



프롬프트 엔지니어링이 진화했듯, RAG 역시 전체 맥락을 관리하는 거대한 시스템 아키텍처로 리브랜딩 되었습니다.



도구가 아닌, 아키텍처를 설계하는 눈.

'RAG is Dead'라는 자극적인 문구에 휘둘려 가장 강력한 검색 도구를 버리지 마십시오.
오늘 다룬 파이프라인을 이해했다면, 이제 상황에 맞춰 도구를 취사선택할 수 있는 아키텍트의 시야를 갖게 된 것입니다.

- 범용 비정형 데이터인가?
→ Semantic Search (Dense)

- 전문 용어가 필수적인가?
→ Hybrid Search (+Sparse)

- 최상위 정확도가 필요한가?
→ Reranker 도입

AI 에이전트 시대, 정교하게 설계된 RAG는 대체 불가능한 핵심 엔진입니다.